

專題報告

A. Introduction

現在工廠越來越走向自動化，很多作業都希望能用電腦幫忙即時監控，像是能不能自動知道工人現在在做什麼動作，有沒有做錯、或者是不是在危險的狀態。這些資訊如果能即時判斷出來，不但可以幫助管理，也能提升工作安全和效率。

所以我們這次的專題就是要做一套「線上動作偵測 (Online Action Detection, OAD)」的系統，讓電腦可以一幀一幀地去看影片，並判斷出當下工人是在「拿螺絲」、「鎖螺絲」、「撕膠帶」，還是沒有動作（背景）。整個系統的目標是做到即時又準確的判斷。

我們參考的模型叫做 TeSTra，是一個專門為即時影片分析設計的架構。它的設計可以讓系統在處理長時間的影片時，速度還是保持得很快，而且記憶的長短期資訊都有考慮到。這個架構是基於一個叫 LSTR 的模型再進一步優化的，我們的實作也是沿用這樣的設計。

透過這個專題，我們想要了解 OAD 的整體流程，從資料處理、模型訓練到結果分析，看看在不同的訓練條件下，系統的準確率會有什麼差別。

B. Method

這次專題的整體流程主要是建立在 TeSTra 這個架構上，這是一個專門針對「線上動作偵測」任務設計的模型。我們的目標是希望影片在輸入後，系統能即時判斷出每一幀中工人正在做的動作，而且運算速度要夠快，不能太耗資源。


我們的流程大致可以分成以下幾個部分：

1. 資料處理：

首先我們會從原始影片中提取每一幀的 RGB 資料，搭配光流 (Optical Flow) 特徵，這兩種資料是後續模型訓練和預測的主要輸入來源。

2. 模型架構：

我們的模型架構是參考 TeSTra 的設計，它改良自 LSTR 模型，最大特色就是能同時保留「長期記憶」和「短期記憶」的資訊，並使用一種叫做「Exponential Smoothing Attention (ES-Attention)」的注意力機制，讓模型每處理一幀的時候，不需要重複計算整段影片的內容，節省大量運算時間。



圖一：LSTR 模型架構

3. 參數設計與優化：

這部分我們主要是沿用助教提供的預設參數來進行訓練，像是 batch size、learning rate、時間窗口（temporal window）等都沒有特別去調整。雖然沒有做太多超參數微調，但我們做了兩次主要的實驗。第一次是用部分資料來訓練，當作 baseline；第二次則是加入更多的訓練資料，希望能提升模型的學習效果。

C. Experiment

為了驗證我們的動作偵測系統效果，我們設計了兩組實驗來進行比較，主要是觀察訓練資料量對模型表現的影響。我們使用的評估指標是 mAP（mean Average Precision），這也是這次作業的主要評分標準之一。

實驗設定：


我們的訓練資料與模型架構都沿用助教提供的設定，包含：

- 使用的特徵：TSN 提取的 RGB + 光流特徵
- 模型架構：TeSTra（含 ES-Attention 機制）
- 動作類別：背景、拿螺絲、鎖螺絲、撕膠帶
- 訓練參數：使用預設的 batch size、learning rate、訓練輪數（epoch）等

兩次實驗的差異在於訓練資料量：

- **實驗一（Baseline）**：使用部分影片進行訓練

- 實驗二 (More Data)：加入更多影片進行訓練



圖二：訓練過程 GPU 使用情形

實驗結果：

實驗版本	使用資料量	mAP (mean Average Precision)	Train loss	Test loss	Epoch
實驗一 (Baseline)	部分訓練影片	99.476%	0.0414	0.01269	100
實驗二 (More Data)	全部訓練影片	99.652%	0.04989	0.01138	100

從結果來看，第二次實驗使用更多資料後，模型的準確率有略微提升，這也顯示資料量對於模型學習效果還是有一些影響。

此外，我們也觀察到，雖然沒特別做超參數調整，但模型整體預測結果已經相當穩定。如果有更多時間，我們認為還可以透過後處理方式（例如對預測結果做時間上的平滑處理）進一步提升辨識準確率。

D. Conclusion

這次的專題讓我們實際體驗了線上動作偵測系統從頭到尾的建構流程，包含資料處理、模型訓練、實驗設計以及結果分析。透過 TeSTra 這個架構，我們成功建立了一個可以即時判斷影片中動作的系統，並且在 mAP 表現上有不錯的成果。

從實驗結果來看，Baseline 模型在只用部分影片訓練的情況下，mAP 達到 99.476%；而當我們把全部訓練影片都加進來後，模型的 mAP 更進一步提升到 99.652%。雖然兩者差距不算非常大，但可以看出使用更多資料對模型表現還是有幫助的，尤其在 Test loss 上也有略微下降，代表模型在看不見的資料上也能維持穩定的預測能力，這也證明資料量對這類時序任務真的很重要。